

数据

50 steps, 100 prompt

每个prompt采用一组threshold进行加速推理

每个数据包括：

50 timestep, 50 latent, 50 thresholds （是否跳过的action）, 1 speedup, 1 psnr (与不加速全量计算生成的视频计算得到)

目标

给定加速比，在每个step利用agent决策是否跳过，在目标加速比下实现最高psnr

框架

state

$$S_t = [timestep, \Delta z_t, Speedup_{target}, Speedup_{current}, C_t]$$

timestep: 归一化时间步

latent特征

期望加速比

已经实现的加速比（根据已经跳过的步数计算得到）

连续跳步计数器

Policy Network

input: state

output: {0,1} 是否跳过

State transition

$$z_{t-1} = \begin{cases} \text{DenoiseCore}(z_t, t), & \text{if } a_t = 0 \\ z_t \quad (\text{或快捷插值}), & \text{if } a_t = 1 \end{cases}$$

Reward function

1. 即时reward

$$r_t = -\lambda_1 \cdot \text{MSE}(z_{t-1}, z_{t-1}^{gt}) - \lambda_2 \cdot (1 - a_t)$$

其中： z^{gt} 为无加速原版 Baseline 推理轨迹

2. 终端稀疏奖励 $R_{Terminal}$

$$R_{Terminal} = \lambda_3 \cdot \text{PSNR}(\text{Video}_{pred}, \text{Video}_{gt}) - \lambda_4 \cdot |S_{achieved} - S_{target}|$$

离线IQL训练算法

网络架构

1、 $V_\psi(s)$

输入：状态向量 s_t

输出：一个标量 $V(s_t) \in \mathbb{R}$ ，代表当前状态下的期望长期综合回报

2、 $Q_\theta(s)$

输入：状态向量 s_t

输出：一个 2 维向量 $[Q(s_t, 0), Q(s_t, 1)]$ ，分别代表采取不跳步和跳步的长期价值。

3、 $\pi_\phi(s)$

输入：状态向量 s_t

输出：2 维的 Logits，经过 Softmax 后代表选择 $\{0, 1\}$ 的概率。

离线数据集

$$= \{(s_t, a_t, r_t^{total}, s_{t-1}, \text{done})\}$$

Training steps

- step1: 更新V函数

计算当前 Batch 在目标 Q 网络中的估计值（取双 Q 的较小者）：

$$Q_{target}(s_t, a_t) = \min(Q_{\hat{\theta}_1}(s_t, a_t), Q_{\hat{\theta}_2}(s_t, a_t))$$

利用 **Exptile Loss** 更新 V_ψ ：

$$L_V(\psi) = \frac{1}{|B|} \sum_{s_t, a_t} L_2^\tau(Q_{target}(s_t, a_t) - V_\psi(s_t))$$

其中 $L_2^\tau(u) = |\tau - \mathbb{I}(u < 0)| \cdot u^2$ 。

- step2: 更新Q函数

$$y = r_t + \gamma \cdot (1 - \text{done}) \cdot V_\psi(s_{t-1})$$

$$L_Q(\theta_1) = \text{MSE}(Q_{\theta_1}(s_t, a_t), y), \quad L_Q(\theta_2) = \text{MSE}(Q_{\theta_2}(s_t, a_t), y)$$

有限补步长优化, $\gamma=1.0$

- 更新策略网络 $\pi_\phi(s)$

$$L_\pi(\phi) = -\frac{1}{|B|} \sum_{s_t, a_t} \exp(\beta \cdot A(s_t, a_t)) \cdot \log \pi_\phi(a_t | s_t)$$

TODO:

1、每个prompt数据需要更丰富的去噪轨迹，离线强化学习（IQL）的本质是“从不完美的多条路径中组合出一条完美的路径”。

2、在每个 Batch 计算出 A 之后，先在 Batch 内部做一次**标准归一化**，再乘以 β ，避免波动过大