

Adaptive Threshold Predictor Feature/Grid Training Report

摘要

本报告合并自适应 timestep threshold 预测网络的实验配置、训练收敛曲线、不同 latent-derived feature / pooling grid 的定量对比，以及当前实验结论。

核心结论：

- 1. 3-epoch feature/grid ablation 中，最优组合是 2x2x2 temporal_mean，best validation loss 为 0.012259。
- 2. 扩大 pooling grid 没有提升全局最优 validation loss。2x4x4 latent_pool 接近，但参数更多，且过拟合更快。
- 3. temporal_mean 和 latent_pool 明显优于 no-feature / noise-feature baseline，说明 latent-derived feature 确实提供了额外有效信息。
- 4. 方差类和帧差类 feature 在当前 candidate_inverse 标签设定下接近 baseline，暂时不是关键因素。
- 5. 30-epoch 曲线显示 validation optimum 很早出现，之后 train loss 继续下降但 validation loss 恶化，因此当前训练应使用 early stopping，而不是认为固定 3 epoch 已经“完全收敛”。
- 6. hdim16 temporal_mean 达到 best validation loss 0.012254，与 hdim64 基本持平，但参数量只有 3505，后续轻量化主线建议优先验证 hdim16 + temporal_mean + 2x2x2。

实验任务

当前训练采用 candidate_inverse 形式：

项目 设置
--- ---
输入 当前 denoising step、当前 step 的 latent-derived feature、候选视频达到的 PSNR
输出 该候选运行实际使用的 SeaCache threshold，范围 [0, 1]
样本构造 每个 sample、每个 SeaCache threshold candidate、每个 denoising step 生成一条训练样本
数据量 100 samples * 10 thresholds * 50 steps = 50000 examples
split 按 sample_id 分组，80 train samples / 20 validation samples
train examples 40000
validation examples 10000
timestep 归一化 step_index / 49
PSNR 归一化 clamp((psnr - 10) / (50 - 10), 0, 1)
loss SmoothL1Loss

注意：本文中的 validation set 是模型选择用的 holdout validation，不是最终 test set。由于我们已经根据 validation loss 选择 feature、grid 和 hidden dim，最终泛化性能仍需要独立 test split 或 grouped K-fold 验证。

模型结构

缓存 feature 训练使用同一套轻量 MLP trunk。不同 feature/grid 只改变输入 feature 的内容和维度，条件分支和预测头保持一致。

模块 配置
--- ---
feature input 预计算 latent-derived feature，shape [B, feature_dim]

feature projector	Linear(feature_dim, hidden_dim) -> SiLU -> Linear(hidden_dim, hidden_dim) -> SiLU
condition input	[normalized_timestep, normalized_psnr]
condition embed	Linear(2, hidden_dim) -> SiLU -> Linear(hidden_dim, hidden_dim) -> SiLU
fusion	concat feature embedding 和 condition embedding, 维度 2 * hidden_dim
prediction head	Linear(2H,H) -> LayerNorm -> SiLU -> Dropout -> Linear(H,H) -> SiLU -> Linear(H,1) -> Sigmoid
输出	单个 threshold, 范围 [0, 1]

默认 3-epoch ablation 使用 hidden_dim=64。长训补充实验额外比较了 hidden_dim=8/16/64。

Feature 定义

feature	定义 直觉
---	--- ---
latent_pool	对原始 latent 做 AdaptiveAvgPool3d(grid) 后 flatten 保留粗粒度时空分布
temporal_mean	先沿时间维求均值, 再扩展回时序体并做 3D pooling 描述当前 latent 的静态内容强度
temporal_var	先沿时间维求方差, 再扩展回时序体并做 3D pooling 描述时序波动程度
frame_diff_mean	相邻帧一阶绝对差分后, 沿时间维求均值, 再 pooling 描述平均动态变化
frame_diff_var	相邻帧一阶绝对差分后, 沿时间维求方差, 再 pooling 描述动态变化的不稳定性

Grid 与参数量

latent_channels=16 时, 不同 pooling grid 对 feature 维度和模型参数量的影响如下:

grid	pooled cells	feature dim	hidden dim	parameters
---	---:	---:	---:	---:
2x2x2	8	128	64	29377
2x4x4	32	512	64	53953
3x4x4	48	768	64	70337
4x4x4	64	1024	64	86721

扩大 grid 会增加输入信息容量, 但也线性增加 feature projector 的参数量。在当前数据规模下, 较大 grid 更早出现 validation loss 回升。

训练配置

配置项	3-epoch feature/grid ablation	30-epoch convergence check
---	---	---
dataset mode	candidate_inverse	candidate_inverse
optimizer	AdamW	AdamW
learning rate	1e-3	1e-3
weight decay	1e-4	1e-4
batch size	256	256
epochs	3	30
split seed	42	42
split method	group by sample_id	group by sample_id
train/val examples	40000 / 10000	40000 / 10000
saved artifacts	config.json, split.json, metrics.json, best_model.pt, final_model.pt, val_predictions.csv	同左

Control Baseline 配置

control	配置 目的
---------	---------

| --- | --- | --- |

| condition_only | 移除 feature branch，只输入 timestep + PSNR | 衡量条件变量本身能解释多少 threshold label |

| noise_feature | 保留 feature projector 和预测 trunk，但 feature 输入替换为随机噪声 | 排除“参数量/结构”本身带来的虚假收益 |

noise_feature 的参数量与 2x2x2 feature 模型相同，都是 29377；condition_only 参数量为 12865。

结果来源

主要训练结果来自以下归档目录：

| 用途 | 目录 |

| --- | --- |

| 2x2x2 feature ablation | /hy-tmp/wan22_adaptive_threshold_feature_ablation_cached_20260616_012409 |

| larger grid ablation | /hy-tmp/wan22_adaptive_threshold_grid_ablation_20260616_020314 |

| no-feature / noise controls | /hy-tmp/wan22_adaptive_threshold_controls_20260616 |

| 30-epoch long runs | /hy-tmp/wan22_adaptive_threshold_feature_ablation_long_20260616 |

| hdim 8 / 16 long runs | /hy-tmp/wan22_adaptive_threshold_feature_ablation_hdim8_20260616, /hy-tmp/wan22_adaptive_threshold_feature_ablation_hdim16_20260616 |

图、表和本文中的 summary 数字由以下脚本统一生成：

```
bash

/hy-tmp/miniconda3/envs/Wan2.2/bin/python -m
experiments.adaptive_threshold_predictor.plot_training_curves \
--out_dir reports/assets/adaptive_training_curves
```

输出文件：

- reports/assets/adaptive_training_curves/training_curve_summary.csv
- reports/assets/adaptive_training_curves/training_curve_summary.json
- reports/assets/adaptive_training_curves/feature_curves_2x2x2.svg
- reports/assets/adaptive_training_curves/grid_val_curves_by_feature.svg
- reports/assets/adaptive_training_curves/best_val_loss_heatmap.svg
- reports/assets/adaptive_training_curves/long_run_curves.svg

图表总览

| 图 | 内容 |

| --- | --- |

| feature_curves_2x2x2.svg | 2x2x2 下五个 feature 的 train/validation loss 曲线 |

| grid_val_curves_by_feature.svg | 每个 feature 在四个 pooling grid 下的 validation loss 曲线 |

| best_val_loss_heatmap.svg | feature × grid 的 best validation loss 热图，并标注参数量 |

| long_run_curves.svg | hdim8/16/64 的 30-epoch train/validation loss 曲线 |

不同 Feature 的 2x2x2 曲线

2x2x2 grid 下，五个 feature 的 best validation loss 排名如下：

rank feature params best epoch best val loss best val MAE last val loss
---: --- ---: ---: ---: ---: ---:
1 temporal_mean 29377 2 0.012259 0.120107 0.013371
2 latent_pool 29377 2 0.012755 0.116558 0.014755
3 frame_diff_mean 29377 3 0.014569 0.132957 0.014569
4 temporal_var 29377 1 0.014595 0.129695 0.014773
5 frame_diff_var 29377 2 0.014659 0.131198 0.014911

观察：

- temporal_mean 的 validation loss 最低，当前是 loss-based 最优 feature。
- latent_pool 的 validation MAE 最低，但 validation loss 略高于 temporal_mean。
- 方差类和帧差类 feature 明显弱于 temporal_mean / latent_pool，与 no-feature control 接近。
- temporal_mean 和 latent_pool 在第 2 epoch 达到最好 validation loss，第 3 epoch train loss 继续下降但 val loss 上升，说明短训阶段已经出现过拟合趋势。

不同 Grid 的 Validation 曲线

下表列出 3-epoch grid ablation 的全量 best validation loss 排名：

rank grid feature params best epoch best val loss best val MAE last val loss
---: --- --- ---: ---: ---: ---: ---:
1 2x2x2 temporal_mean 29377 2 0.012259 0.120107 0.013371
2 2x4x4 latent_pool 53953 1 0.012434 0.118093 0.016158
3 4x4x4 latent_pool 86721 1 0.012733 0.118652 0.016058
4 2x2x2 latent_pool 29377 2 0.012755 0.116558 0.014755
5 3x4x4 temporal_mean 70337 1 0.013236 0.124000 0.015243
6 2x4x4 temporal_mean 53953 1 0.013368 0.120277 0.015199
7 3x4x4 latent_pool 70337 1 0.013909 0.121416 0.015346
8 4x4x4 temporal_mean 86721 1 0.014222 0.122172 0.015309
9 2x4x4 frame_diff_var 53953 3 0.014491 0.131235 0.014491
10 3x4x4 frame_diff_var 70337 3 0.014519 0.128593 0.014519
11 3x4x4 frame_diff_mean 70337 3 0.014545 0.128772 0.014545
12 2x4x4 temporal_var 53953 3 0.014567 0.129576 0.014567
13 2x2x2 frame_diff_mean 29377 3 0.014569 0.132957 0.014569
14 4x4x4 frame_diff_var 86721 2 0.014577 0.130000 0.014607
15 2x2x2 temporal_var 29377 1 0.014595 0.129695 0.014773
16 2x4x4 frame_diff_mean 53953 2 0.014630 0.129683 0.014736
17 2x2x2 frame_diff_var 29377 2 0.014659 0.131198 0.014911
18 4x4x4 temporal_var 86721 3 0.014705 0.128684 0.014705
19 3x4x4 temporal_var 70337 3 0.014718 0.128338 0.014718
20 4x4x4 frame_diff_mean 86721 2 0.014745 0.129399 0.014964

观察：

- 扩大 grid 没有带来更低的 best validation loss。
- 2x4x4 latent_pool 是最接近的 larger-grid 结果，但参数量从 29377 增加到 53953，且第 1 epoch 后 validation loss

快速上升。

- 3x4x4 和 4x4x4 参数更多，best epoch 多数提前到第 1 epoch，显示出更强过拟合。
- 当前 loss-based 默认仍应选择 2x2x2 temporal_mean。

Feature x Grid Heatmap

每个 feature 的最佳 grid：

feature	best grid	best epoch	best val loss
latent_pool	2x4x4	1	0.012434
temporal_mean	2x2x2	2	0.012259
temporal_var	2x4x4	3	0.014567
frame_diff_mean	3x4x4	3	0.014545
frame_diff_var	2x4x4	3	0.014491

这里需要注意：虽然 latent_pool 在 2x4x4 下优于 2x2x2 latent_pool，但全局最优仍是 2x2x2 temporal_mean。因此扩大 grid 对某个 feature 局部有帮助，但没有提升整体最优结果。

Control Baseline

setting	params	best epoch	best val loss	best val MAE
noise_feature	29377	1	0.014648	0.131173
condition_only	12865	3	0.014652	0.128916
temporal_mean	29377	2	0.012259	0.120107
latent_pool	29377	2	0.012755	0.116558

结论：

- 仅使用 timestep 和 PSNR 已经能解释相当一部分 label 结构。
- 真实 latent-derived feature 仍然显著优于 no-feature/noise baseline。
- temporal_mean 相比 condition_only/noise_feature 的 validation loss 大约下降 13% - 16%。

30-Epoch 收敛性检查

长训结果如下：

group	feature	params	best epoch	best val loss	last val loss
hdim16	temporal_mean	3505	4	0.012254	0.021120
hdim16	latent_pool	3505	4	0.012473	0.018201
hdim64	temporal_mean	29377	1	0.012571	0.019334
hdim64	latent_pool	29377	3	0.012612	0.023170
hdim8	latent_pool	1433	4	0.013039	0.016017
hdim8	temporal_mean	1433	6	0.013240	0.019828

观察：

- 30-epoch runs 明确显示：train loss 持续下降，但 validation loss 在早期达到最低后持续恶化。
- 因此不能说 3 epoch 已经“完全收敛”。更准确地说，当前任务在少数 epoch 内就达到 validation 最优点，之后继续训练主要是在拟合 train split。
- hdim16 temporal_mean 达到最低 validation loss 0.012254，与 hdim64 2x2x2 temporal_mean 的 0.012259 基本持平，但参数量只有 3505。这说明当前数据规模和 label 结构下，进一步缩小 hidden dim 是合理方向。

结论

1. 当前最优 feature/grid 组合仍是 2x2x2 temporal_mean，best validation loss 为 0.012259。
2. 扩大 pooling grid 没有改善全局最优 validation loss。2x4x4 latent_pool 接近，但参数更多且过拟合更快。
3. 方差类和帧差类 feature 在当前 candidate_inverse 设定下没有显示出关键作用，loss 接近 no-feature/noise baseline。
4. timestep + PSNR 是强 baseline，但真实 latent-derived feature 仍然提供了有效增益。
5. 训练不是 3 epoch 完全收敛，而是 validation optimum 很早出现。后续训练应使用 early stopping，而不是固定长训。
6. 下一步建议使用 hdim16 + temporal_mean + 2x2x2 做主线验证：它和 hdim64 的 best validation loss 基本相同，但参数量下降到约 3.5K，更符合轻量化目标。